Data Analytics com R e Bancos de Dados – SQL e NOSQL

Flávio Brito

DBI (*R* Database Interface)

- Disponibiliza uma interface comum a maioria dos pacotes do R para bancos de dados. Todas as classes neste pacote são virtuais, sendo assim necessitam ser estendidas por várias implementações utilizando códigos específicos em sub-pacotes
  - **RMySQL, RPostgreSQL, ROracle, RSQLite, RJDBC**
- Utiliza funções para abrir e fechar conexões
  - dbConnect(), dbDisconnect(),

```
con < -  dbConnect(RMySQL::MySQL(),
    username = “usuario",
    password = “senha",
    host = "192.168.100.143",
    port = 3306,
    dbname = "mysql")
```

Utilizando o DBI

- dbListTables() – lista as tabelas do banco de dados
- dbReadTable() e dbWriteTable() – são funções para executar respectivamente a leitura de tabela e escrita de tabelas. O dbReadTable() utiliza o identificados row_names

```
df < - dbReadTable(con, "funcionario")
```

- dbGetQuery() – submete o comando SQL e retorna o conjunto de dados após o processamento

```
df_bd < - dbGetQuery(con, "SELECT * FROM user")
```

As funções dbSendQuery() e fetch() – são utilizados para transmitir grande volume de dados

Outras funções avançadas também estão disponíveis para acesso a definição de schemas, manipulação de transações, e chamada de procedures.

SQL simples

- Buscar uma coluna sem filtragem e de forma distinta

```
df <-dbGetQuery(con, "SELECT DISTINCT codigo FROM pedido")
```

- Agregação e ordenação de resultados

```
df <-dbGetQuery(
    con,
    "SELECT cargo, avg(salario_liquido) as MEDIA_SAL
FROM folha GROUP BY cargo ORDER BY MEDIA_SAL DESC"
)
```

Carregando um DF para o BD

```
data("mtcars")
df < - mtcars
dbWriteTable(con,
    "mtcars",
    value = df,
    append = TRUE,
    row.names = FALSE)
dbListTables(con)
df_bd < - dbGetQuery(con, "SELECT * FROM mtcars")
head(df_bd, 4)
```

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
1	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
2	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
3	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
4	21.4	6	258	110	3.08	3.215	19.44	1	0	3	1

Indo além

- # carregando os dados

```
tabela_B < - dbGetQuery(con, "SELECT * FROM amostras JOIN
tabela_A USING (codigo)")
```

- # O mesmo resultado do join se consegue em R com a função merge()

```
tabela_B < - merge(amostras, tabela_A, by = "codigo")
```

- #usando a função merge só que para campos com nomes diferentes

```
tabela_B < -
    merge(amostras, tabela_A, by.x =  “cod_am", by.y =
“codigo_a")
dbDisconnect(con)
```

Visualizando os dados – BD, GGPLOT, GGTHEMES

```
require(ggplot2)
require(ggthemes)
df_bd <-dbGetQuery(con, "SELECT
* FROM mtcars")
g < -ggplot(df_bd, aes(
    x = as.factor(cyl),
    y = mpg,
    fill = as.factor(cyl)
)) +
    geom_boxplot()
g + theme_economist() +
scale_color_economist() +
ggtitle("Consumo por
cilindradas")
```

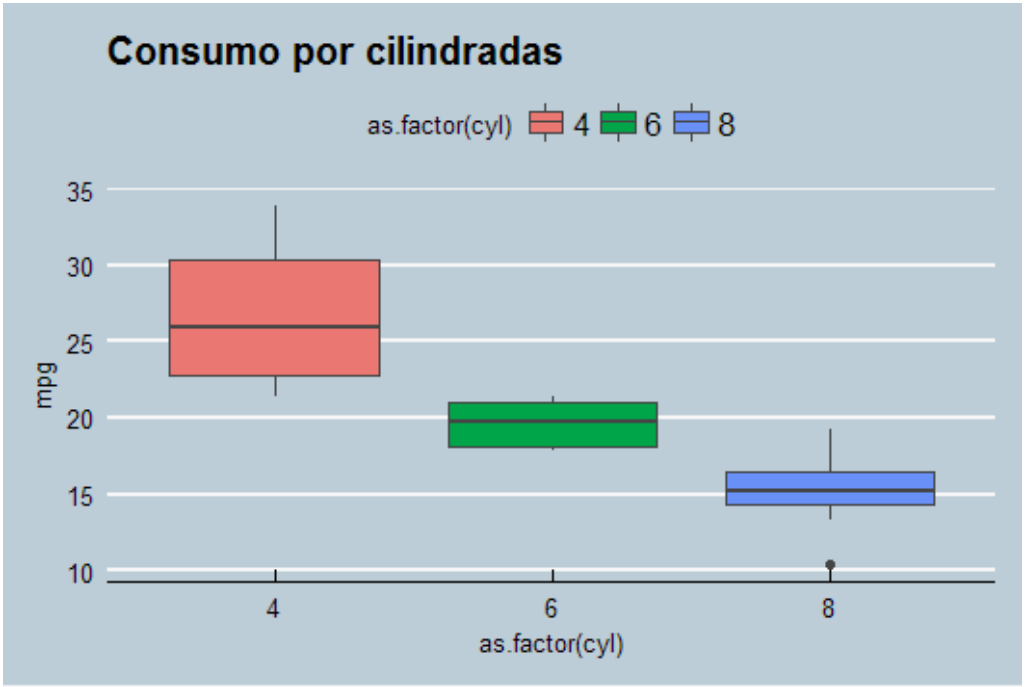

Exemplo de conexão com Bancos

MySQL (RMySQL)

- RMySQL: Esta versão está em acordo com as definições implementadas no pacote DBI 0.2-2.
- TSMySQL: Ele fornece uma extensão da interface Tsdbi (Time Series Database Interface) para manipulação de séries temporais no MySQL.

```
con < -  dbConnect(
    RMySQL::MySQL(),
    username = "usuario",
    password = "senha",
    host = "192.168.100.143",
    port = 3306,
    dbname = "mysql"
)
```

PostgreSQL (RPostgreSQL)

- RPostgreSQL: Interface R para o Banco de Dados PostfreSQL
- TSPostgreSQL: Oferece uma extensão da interface Tsdbi para PostgreSQL

```
library(RPostgreSQL)
con < -
    dbConnect(
        'PostgreSQL',
        user = 'USUARIO',
        password = ‘SENHA', host = ‘192.168.1.10',
        port = 5432,
        dbname = ‘MEU_BANCO')

data(iris)
dbWriteTable(con, 'iris', iris, row.names = FALSE)
output < - dbGetQuery(con, "SELECT * FROM iris")
summary(output)
```

```
 Sepal.Length    Sepal.Width     Petal.Length    Petal.Width          Species
 Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100   setosa    :50
 1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300   versicolor:50
 Median :5.800   Median :3.000   Median :4.350   Median :1.300   virginica :50
 Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
 3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
 Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
```

ODBC (RODBC)

```
library(RODBC)
con <-odbcConnect("DSN1",
    uid = "usuario",
    pwd = "senha",
    rows_at_time = 500)
sqlSave(con, test_table, "TEST_TABLE")
sqlQuery(con, "SELECT COUNT(*) FROM TEST_TABLE")
d < -sqlQuery(con, "SELECT * FROM TEST_TABLE")
close(con)
```

- Onde:
  - **odbcConnect(*dsn*, uid="", pwd="")** - abre uma conexão
  - **sqlFetch(*channel*, *sqtable*)** – Lê uma tabela para um data frame
  - **sqlQuery(*channel*, *query*)**
  - **sqlSave(*channel*, *mydf*, tablename = *sqtable*, append = *FALSE*)** – grava ou atualiza (append =TRUE) um data frame para a tabela na base do ODBC

Oracle(RORACLE)

```
library(RJDBC)
drv < - JDBC("oracle.jdbc.OracleDriver",
    classPath = "…tklocal/instantclient_11_2/ojdbc5.jar", " ")
con < - dbConnect(drv, " jdbc:oracle:thin:@192.168.1.10:1521:db",
"usuario", "senha")
dbWriteTable(con, "TEST_TABLE", test_table)
dbGetQuery(con, “SELECT COUNT(*) FROM TEST_TABLE")
d<- dbReadTable(con, "TEST_TABLE")
dbDisconnect(con)
```

```
library(ROracle)
drv< - dbDriver("Oracle")
          con< - dbConnect(drv, "usuario", "senha")
          dbWriteTable(con, ”TEST_TABLE”, test_table)
          dbGetQuery(con, “SELECT COUNT(*) FROM TEST_TABLE")
d< - dbReadTable(con, "TEST_TABLE")
dbDisconnect(con)
```

SQLite

- RSQLite: Este pacote embarca a engine do banco de dados SQLite e fornece uma interface compatível com o pacote DBI
- TSSQLite: Forncece uma extensão da interface Tsdbi para o SQLite

```
con < - dbConnect(RSQLite::SQLite(), ":memory:")
dbWriteTable(con, "iris", iris)
dbGetQuery(con, "SELECT * FROM iris WHERE [Petal.Width] > 2.3")
dbDisconnect(con)
```

MongoDB

- RMongo: Interface para R com MongoDB. Utiliza Java.
- rmongodb: Fornece interface ao MongoDB para R. Removido do CRAN.
- mongolite – Interface leve para conexão do R com o MongoDB.

```
library(RMongo)
mongo < - mongoDbConnect("SER", "localhost", 27017)
output < -
    dbInsertDocument(
        mongo,
        "evento2",
        '{nome:"Flavio", sobrenome:"Brito",
email:"flaviobrito@live.com"}'
```

MongoDB

```
db.evento.drop()
db.createCollection('evento');
show collections
db.evento.insert({ nome: "Flavio", sobrenome: "Brito",
email: "flaviobrito@live.com" });
db.evento.find()
db.evento.insert([{ nome: "Antonio", sobrenome: "Jose",
email: "ajose@gmail.com" }, { nome: "Jose", sobrenome:
"Manoel", email: "jmanoel@gmail.com" }]);
db.evento.find()
```

Obrigado

Data Analytics com R e Banco de Dados - SQL e NOSQL

Flávio Brito - Fundação CECIERJ

E-mail: flaviobrito@live.com

https://www.github.com/flaviobrito/IISERUFF